Ключевые выводы EDA логов LogHub

Разобраны 16 систем в 7 Jupyter-ноутбуках. Разметка аномалий есть только у BGL, Thunderbird (alert-категории строк), HDFS_v1 (блоки), Hadoop (сценарии запусков) и OpenStack (4 машины со сбоями); остальные датасеты представлены без ground truth-лейблов. Приложения, которые мы рассматривали, были представлены в нескольких категориях, о которых пойдет речь ниже.

Распределённые системы и облако

HDFS. v1: 11,2 млн строк за 38 часов, хронология целостна, есть разметка аномальных блоков (единиц хранения в HDFS), есть полные дубли, но их немного. v2-датасет хранит больше данных: с 2015 по 2017, разметка отсутствует, аналогично небольшое количество дублей, около четверти строк без меток времени (многострочные Java-эксепшены), перекос записи между DataNode, был всплеск активности всплеск в середине периода. v3-версию (с инструментацией TraceBench) пропустили: это специальный датасет с трейсами, а не сырой текстовый лог, над которыми нам предстоит строить production-систему.
Spark. Более 3500 файлов, 195 приложений, медианная длина файла 53 строки; у трети файлов проблемы с разметкой временем, у 96 нарушена хронология. Джобы короткие, - скорее всего, аномалию надо привязывать непосредственно к таске.
Hadoop. 978 файлов, 394к строк → 180 896 событий, 4 586 шаблонов, 214 689 точных повторов. 55 тасок: 11 штатных, 28 с отключением машины, 7 с отключением сети, 9 с заполнением диска. Лучший кандидат для первой модели с разметкой.
OpenStack. 3 файла, 208к строк, 433 шаблона, без дублей и скачков времени. Только 4 размеченные машины, явно упомянуты в 112 событиях.
ZooKeeper. 74 380 строк за 26,7 суток, поля host нет. WARN 65,2% (не аномалия), 617 строк с уровнем критичности ERROR. 96% пустых минут, 415 инверсий времени, 1 988 дублей, 1 791 session ID, 77 шаблонов.

Суперкомпьютеры

BGL. Лог суперкомпьютера: 4,75 млн строк с июня 2005 по январь 2006. Каждая строка заранее помечена как норма или аномалия. Аномалий 348к, т.е. 7,3% строк. Алерты, между которыми не больше 5 минут, мы объединили в «эпизоды»: их 816. Десять крупнейших эпизодов дают почти две трети (64,8%) всех алертов, то есть алерты собраны в немногие крупные всплески. 91,1% сообщений приходит от одного компонента, RAS/KERNEL. Разных типов сообщений (шаблонов) около 312, это оценка по выборке в 100 тыс. строк. Слово error в тексте не значит алерт.
Thunderbird. 211 млн строк, 29,6 GiB, 244 дня. Alert 1,54%, из них 99,41% — VAPI; самая нагруженная минута (205 034 строки) без alert. Тексты и 1 068 шаблонов оценены на выборке 100 тыс. строк. Нужна оценка с учётом дисбаланса.
HPC. 433к строк (2003–2006), 228к случаев инверсии времени, пауза 125,7 суток, 1 161 шаблон, 88,6% пустых минут. Поле numeric_flag не расшифровано.

ОС, приложения и сервисы

Linux. Нет severity, 20 строк с ошибками кодировки, дубли и инверсии, мощный всплеск OOM ближе к концу.

Mac. 117к строки, 107к событий за 7 суток, 636 шаблонов, 70,6% пустых минут, 560 инверсий, 1068 многострочных событий. 4377 записей «last message repeated» занижают реальный объём.
Windows. 114,6 млн строк, CBS 99,9%, 102 шаблона (топ-10 = 96,7%). Охват 226 дней по порядку файла, но 1157 дней по min–max; 99,2% пустых 5-минутных окон.
Android. 1,56 млн строк за сутки, 71 109 шаблонов (топ-10 лишь 17%), 137801 повтор, 418 инверсий, 46,7% пустых минут. Год неизвестен.
HealthApp. 253к строк за ~11 суток, 202 шаблона, 59 инверсий, Step_LSC 32,1%, 23,9% пустых окон.
Apache. 56к строк, 4478 без заголовка, 190 инверсий, 133 шаблона, 90,9% пустых окон.
OpenSSH. 655к строк за 28 суток, 100% sshd, 45 шаблонов; 140 768 «Failed password», 1187 IPv4, картина автоматического перебора паролей.
Proxifier. Однородный строго типизированный лог, одна инверсия, много дублей (возможно heartbeat), подозрительный пик в конце.

Практическая ценность исследования

Воспроизводимая база. Единый чеклист из 11 пунктов, общий код (util/loghub_*.py) с тестами, архивы Zenodo с закреплёнными MD5/SHA-256, фиксированный seed. Тот же пайплайн применим к логам целевой облачной системы.
Выбор данных для моделей. Hadoop - первая модель с разметкой (известны границы тасок и сценарии); OpenStack - ближе всего к облаку; BGL и Thunderbird - большие наборы с построчными метками для проверки на перекос; Mac, Android, HPC, OpenSSH, ZooKeeper - отладка парсинга и методов без разметки (unsupervised learning).
Требования к предобработке. Склеивать многострочные события (HDFS_v2, Mac, Apache); сортировать события внутри хоста (HPC); сохранять пустые сообщения (в BGL 34к записей терялись); не удалять дубли и не разворачивать syslog-повторы автоматически; чинить разбор дат (HealthApp).
Защита от ошибок оценки. ERROR/WARN != метка аномалии (ZooKeeper: WARN 65%); всплеск объёма не равен аномалии (Thunderbird); пустые окна от 3% до 99% нельзя читать как простой; accuracy при дизбалансе классов как метрика неинформативна; сплит по времени и по целым эпизодам; словарь шаблонов Drain3 только на train.
Кандидаты в фичи. Частоты шаблонов по окнам, объём потока, доли уровней и компонентов, длины сообщений, паузы. Размер окна выбирать по целевой задержке определения аномалии; редкие шаблоны и объём - два разных сигнала.
Общее. Пустые минуты, инверсии и дубли встречаются почти везде, их нельзя без проверки считать простоем или мусором.